

Ronald Eduardo Barberi Riaño

Científico e Ingeniero de Datos | Machine Learning · Big Data/ETL · Analítica de Datos

Bogotá D.C., Colombia | tethor60@gmail.com | +57 320 498 7683

linkedin.com/in/ronald-eduardo-barberi-riaño-rebr | github.com/RonaldBarberi | Remoto o híbrido

Perfil profesional

Data Scientist y Data Engineer senior con más de 6 años de experiencia en análisis, ciencia e ingeniería de datos para banca, medios de pago, tecnología y BPO. Cubro el ciclo completo del dato: ingesta batch y streaming (PySpark, Apache NiFi, AWS Glue) sobre más de 5.000 millones de registros, feature engineering a escala de terabytes, análisis estadístico inferencial, modelos de machine learning en producción (churn, NBO/NBA, clasificación) con MLOps en AWS SageMaker y reportería de KPIs para la alta dirección. Impulsé un crecimiento del 275 % en campañas, un aumento estimado del 20 % en la efectividad de promociones y la retención estimada del 8 % de los clientes en fuga.

Habilidades técnicas

Análisis y BI: SQL (SQL Server, MySQL, PostgreSQL, Athena/Presto, Hive, Impala), Power BI, Tableau, Looker, estadística descriptiva e inferencial, análisis exploratorio (EDA), R, reportería de KPIs, Excel avanzado (macros), Matplotlib, Seaborn, Erlang C

Ingeniería de datos: Python, PySpark / Apache Spark, Pandas, Polars, NumPy, ETL/ELT batch y streaming, Apache Airflow, dbt, Apache Kafka, Apache NiFi (Groovy), Databricks, Snowflake, BigQuery, Cloudera (Hive, Impala, HUE), AWS Glue, Amazon EMR, Amazon S3, APIs, web scraping (Selenium), Java

Ciencia de datos y ML: scikit-learn, XGBoost, LightGBM, TensorFlow / Keras, modelos de clasificación, sistemas de recomendación (NBO/NBA), modelos de churn, feature engineering, MLflow, monitoreo de modelos (MLOps), Amazon SageMaker (JumpStart), visión por computador (OpenCV, MediaPipe), agentes LLM (Claude)

Cloud, DevOps y APIs: AWS (S3, EC2, EMR, Glue, Athena, SageMaker, CloudWatch, CodeCommit), Cloudera, Azure (formación), Docker, Git / GitHub, GitHub Actions (CI/CD), FastAPI, Django, Linux (administración de servidores), Automation Anywhere 360 (RPA)

Metodologías: Scrum, código limpio, PEP 8

Experiencia

Data Coordinator Business (Bilingüe)

07/2026 – 10/2026

Samsung

- Desarrollé modelos de clasificación binaria en Python y PySpark para seleccionar las promociones dirigidas a cada cliente, con un aumento estimado del 20 % en la efectividad de las promociones.
- Creé skills y agentes de IA con Claude (LLMs) que automatizaron ~15 procesos de monitoreo, migración y operación, ahorrando ~10 horas de trabajo al día.
- Construí ETLs batch y de streaming en PySpark que procesan ~15 GB por flujo y almacenan los datos procesados en MySQL para su consumo por el negocio.
- Diseñé los reportes de KPIs que la Presidencia de la compañía revisa en detalle para el seguimiento de los indicadores del negocio.
- Automaticé procesos con Python y Automation Anywhere 360, y configuré los servidores Linux y las bases de datos MySQL que los ejecutan.

Tecnologías: Python, PySpark, MySQL, Linux, Automation Anywhere 360, Claude (LLM)

Data Scientist (Middle)

11/2025 – 07/2026

Itaú (vía Multiplika)

- Construí un framework de feature engineering en Python y Spark sobre Amazon EMR que procesa terabytes de datos y genera las tablas maestras de ML de ~7 proyectos, ahorrando ~6 horas de preparación de datos.
- Mantuve y ejecuté en producción, sobre AWS SageMaker, los modelos de recomendación de promociones para clientes (Next Best Offer y Next Best Action), el modelo de abandono de clientes (Churn 360) y SPOT.
- Implementé el monitoreo continuo de modelos en producción bajo estándares MLOps con SageMaker y CloudWatch, asegurando calidad y seguridad y emitiendo recomendaciones de reajuste.
- Operé y mantuve pipelines ETL de gran volumen con AWS Glue, S3 y Athena (SQL-Presto) que soportan reportes y procesos operativos.
- Desarrollé un framework de transformación de alto nivel en Python para el análisis y tratamiento estadístico univariado de datos, reutilizable entre proyectos de modelado.

Tecnologías: AWS (SageMaker, JumpStart, EMR, Glue, Athena, S3, EC2, CloudWatch, CodeCommit), Python, Spark

Ingeniero de Datos

12/2024 – 11/2025

Credibanco (vía Nexos)

- Diseñé y construí flujos ETL con PySpark y Apache NiFi sobre Cloudera (Hive, Impala) para transformar y transferir más de 5.000 millones de registros (~150 columnas) entre diversos proyectos.
- Identifiqué con análisis estadístico inferencial en Python la causa raíz de una fuga de clientes en comercios; las acciones correctivas propuestas recuperaron y retuvieron un estimado del 8 % de los clientes.
- Refactoricé las APIs de Hub Connect con nueva lógica de consumo y reglas de negocio, aumentando su capacidad y liberando recursos de Cloudera (ahorro estimado de COP 9 millones al mes).
- Implementé hashing de valores sensibles y transferencia de información en streaming con Apache NiFi, protegiendo los datos sensibles en los pipelines.

Tecnologías: Cloudera (Hive, Impala, HUE, CDSW, Zeppelin), PySpark, Apache NiFi, AWS, Java, Python (scikit-learn, Pandas)

Data Scientist / Data Mining

04/2022 – 12/2024

Customer Operation Success (COS)

- Lideré un equipo bajo Scrum en la depuración de bases de datos para las campañas de Claro, Laika y carteras, logrando un crecimiento del 275 % que las convirtió en las más rentables del periodo.
- Desarrollé ETLs en Python y PySpark que extraen información de APIs, web scraping (Selenium) y servidores, con procesamiento en streaming.
- Construí EDAs y modelos predictivos (scikit-learn, TensorFlow) para dimensionar y perfilar bases de datos.
- Creé la reportería de KPIs del negocio con plantillas estandarizadas, y automatice procesos ejecutados en servidores Linux (máquinas virtuales).

Tecnologías: SQL, Python, PySpark, Pandas, NumPy, Selenium, scikit-learn, TensorFlow, Matplotlib, Seaborn, Erlang C, Git/GitHub, Docker, Linux

Experiencia previa

- **Analista de Datos** – Ejército Nacional de Colombia (09/2020 – 02/2022): Procedimientos almacenados, vistas y consultas de validación en SQL Server; reportes en Excel con macros para reducir tiempos de entrega.

Proyectos destacados

- **Pipelines ETL multifuente** – github.com/RonaldBarberi/structured_data_etls
ETLs en Python y SQL que extraen datos de sitios web (Selenium), bases MySQL (SQLAlchemy) y archivos locales, con procedimientos almacenados para la depuración de bases de datos.
- **Machine Learning y visión por computador** – github.com/RonaldBarberi/data_science
Clasificador de uso de tarjeta con clases desbalanceadas (Random Forest, ROC-AUC 0.74 en validación cruzada), regresión de costos de mercado validada en periodos no vistos ($R^2 = 0.84$) y reconocimiento de gestos de la mano con OpenCV y MediaPipe (accuracy 98.7 %), con pipelines de scikit-learn.
- **Análisis exploratorio y validación estadística** – github.com/RonaldBarberi/data_analytics
EDA de datos bancarios y del sector BPO con limpieza y validación estadística, entregando datasets listos para entrenar modelos de clasificación binaria.

Educación

Estadística

01/2025 – 12/2027 (estimado)

Fundación Universitaria Los Libertadores – Pregrado (en curso, 6.º semestre)

Especialización en Estadística Aplicada como opción de grado. Grado estimado: 2.º semestre de 2027.

Ingeniería Informática

Escuela Superior de Empresa, Ingeniería y Tecnología (ESEIT) – 4 semestres cursados

Énfasis: infraestructura de software, servidores, bases de datos y Big Data. Transferencia a Estadística.

Certificaciones

- Tecnologías de Azure Data Engineer – Udemy (12/2025)
- Big Data y Spark: ingeniería de datos con Python y PySpark – Udemy (12/2025)
- Arquitecto de Soluciones AWS (preparación AWS Certified Solutions Architect) – Udemy (12/2025)

Idiomas

Español: Nativo | Inglés: Intermedio (B1)